Metody odkrywania wiedzy: Forest Cover Type Prediction

Monika Pawluczuk, Bartosz Lemiec

12 czerwca 2016

1 Interpretacja tematu projektu

Temat dotyczy predykcji typu lasu i oparty jest na danych dostarczonych przez US Forest Service (USFS).

Celem jest przewidzenie zalesienia terenu, a dokładniej określeniu typu drzewa dominującego w danym terenie, z danych kartograficznych. Typ zalesienia został określony, na parcelach o powierzchni 30x30 metrów, przez US Forest Service (USFS). Dane są nieprzeskalowane i zawierają kolumny z wartościami binarnymi dla niezależnych zmiennych jakościowych takich jak obszar czy też typ gleby.

2 Opis algorytmów wykorzystanych w badaniach

2.1 Algorytm K-najbliższych sąsiadów

Algorytm może być stosowany zarówno do zadań klasyfikacji jak i regresji. Jest jednym z najbardziej znanych podejść aproksymacji funkcji na podstawie zapamiętywania. W celu wyznaczenia odpowiedzi na zapytanie dotyczące przykładu bierze się pod uwagę najbliższy mu, według przyjętej metryki, przykład trenujący.

Tak sformułowany algorytm nie wymaga żadnych założeń co do dziedziny i reprezentacji przykładów, oprócz określenie miary odległości. Funkcja miary będzie w rzeczywistości pojęciem, o przeciwdziedzinie będącej zbiorem kategorii.

Algorytm charakteryzuje się bardzo dużą szybkością uczenia się, a jego dokładność zależy od ilości przykładów trenujących oraz funkcji mierzącej odległość.

Zostanie wykorzystany pakiet R class (`https://cran.r-project.org/web/packages/class/class.pdf`). Zakłada on użycie jako metryki odległości euklidesowej.

2.2 Drzewo decyzyjne - algorytm C4.5

Algorytm wykorzystywany do generowania drzew decyzyjnych. Jest rozszerzeniem wcześniejszego algorytmu ID3. Drzewa decyzyjne generowane za pomocą tego algorytmu mogą zostać wykorzystane przy klasyfikacji i dlatego też algorytm ten określany jest często jako klasyfikator statystyczny.

Buduje on drzewo decyzyjne z zestawu danych trenujących, wykorzystując pojęcie entropii informacji. Zestaw trenujący zawiera zaklasyfikowane już przykłady, zawierające

p-wymiarowy wektor $(x_{1,i}, x_{2,i}, \ldots, x_{p,i})$, gdzie x_j reprezentuje wartość atrybutu albo właściwości próbki, oraz klasę do której S_i należy.

Przy każdym węźle drzewa decyzyjnego, algorytm C4.5, wybiera atrybut danych, który z największą efektywnością rozdziela zbiór próbek na podzbiory o większej entropii dla którejś z klas. Kryterium podziału jest entropia względna. Atrybut o największym przyroście informacji jest wybierany, jako ten na podstawie którego tworzone będą kolejne węzły lub liście. Algorytm C4.5 następnie postępuje rekurencyjnie, aby stworzyć pomniejsze podlisty.

Algorytm z góry pokrywa kilka podstawowych przypadków:

- Wszystkie próbki w liście należą do tej samej klasy $\Rightarrow$ w takim przypadku drzewo tworzy liść drzewa wybierający daną klasę.
- Żaden z atrybutów nie niesie ze sobą jakichkolwiek informacji $\Rightarrow$ algorytm C4.5 wykorzystuje węzeł decydujący wyżej w strukturze drzewa i wartość oczekiwaną w nim zawartą.
- Instancja nigdy nie spotkanej wcześniej klasy zostaje znaleziona $\Rightarrow$ algorytm tworzy węzeł wyżej w drzewie wykorzystując jego wartość oczekiwaną.

Zostanie wykorzystany pakiet R RWeka, zawierający implementację algorytmu J48 (`https://cran.r-project.org/web/packages/RWeka/RWeka.pdf`).

2.3 Naiwny klasyfikator bayesowski

Naiwny klasyfikator bayesowski reprezentuje hipotezy za pomocą oszacowań (tworzonych na podstawie zbioru trenującego) pewnych prawdopodobieństw i klasyfikuje przykłady, wybierając dla nich najbardziej prawdopodobne kategorie. Przypomina on optymalny klasyfikator bayesowski, z podstawową różnicą, że nie wykorzystuje żadnych innych hipotez (nawet w celach pomocniczych). Zakłada on ograniczenie się do zestawu atrybutów dyskretnych.

Na podstawie zbioru trenującego szacowane są prawdopodobieństwa poszczególnych kategorii pojęcia docelowego c oraz prawdopodobieństwa poszczególnych wartości atrybutów dla przykładów różnych kategorii. Będą nas interesować oszacowania prawdopodobieństw:

- Prawdopodobieństwo dla każdej możliwej kategorii pojęcia docelowego c
- Prawdopodobieństwo wystąpienia danej wartości atrybutu dla przykładu z danej klasy - dla każdej możliwej kategorii pojęcia docelowego i każdej wartości każdego atrybutu.

Aby obliczyć prawdopodobieństwo kategorii d pojęcia docelowego: wyznaczamy ile jest przykładów z tą klasą w zbiorze trenującym, a następnie dzielimy ją przez ilość wszystkich przykładów w zbiorze trenującym.

Podobnie, aby oszacować prawdopodobieństwo wartości atrybutu $a_i = v$ dla kategorii d, liczymy ile jest przykładów każdej kategorii dla poszczególnych wartości każdego atrybutu i dzielimy uzyskaną przez liczbę wszystkich przykładów tej kategorii.

Wadą tego podejścia jest przypadek, gdy w którejś z grup nie ma żadnego przykładu. Wówczas prawdopodobieństwo jest szacowane na 0, co jest bardzo radykalnym podejściem. W związku z tym stosuje się technikę wygładzania, która jest też zaimplementowana w pakiecie, który będzie użyty w projekcie.

Wygładzanie polega na zastąpieniu wartości zerowej pewną niewielką, lecz dodatnią wartością ϵ. Jest to proste i popularne rozwiązanie, które powinno być dostosowane do do rozmiaru zbioru trenującego. Na pewno wartość ta powinna być mniejsza niż odwrotność liczebności tego zbioru (skoro grupa, której mamy tylko jeden przykład będzie miała prawdopodobieństwo $1/|T|$ - grupa o zerowej liczbie przykładów powinna mieć mniejsze prawdopodobieństwo).

Najczęstszą heurystyką jest przyjęcie epsilonu na poziomie połowy odwrotności liczebności zbioru trenującego $1/2 * |T|$.

Ta sama zasada obowiązuje również przy obliczaniu prawdopodobieństwa klas.

Zostanie wykorzystany pakiet R e1071 (`https://cran.r-project.org/web/packages/e1071/e1071.pdf`). Implementacja zakłada niezależność rozkładów atrybutów (stąd "naiwność" w nazwie) i rozkład Gaussa. Niestety implementacja, w razie brakujących wartości atrybutów pomija przykład ze zbioru trenującego.

3 Plan badań

3.1 Cel badań

Obszar przeznaczony do analizy zawiera cztery lokalizacje w Roosevelt National Forest, znajdującego się w północnym Colorado. Każda obserwacja przeprowadzona została na obszarze 30x30m. Celem jest predykcja typu lasu, który pokrywać będzie dany obszar, w postaci liczby, która to z kolei odpowiada jednemu z siedmiu typów:

Lp.	Nazwa
1	Świerk/jodła
2	Sosna wydmowa
3	Sosna żółta
4	Topola/wierzba
5	Topola osikowa
6	Daglezja zielona
7	Drzewo karłowate

3.2 Charakterystyka zbiorów danych i ich przygotowanie

Zestaw trenujący złożony z 15120 przykładów zawiera zarówno właściwości, jak i typ pokrycia. Zestaw testowy zawiera jedynie właściwości. Celem jest przewidzenie typu pokrycia w każdym z wierszy zestawu testowego (565892 obserwacje).

3.2.1 Kolumny danych

Lp.	Nazwa	Opis	Opis (j.ang.)
1	Elevation	Elewacja wyrażona w metrach	Elevation in meters
2	Aspect	Strona wyrażona w stopniach azymutu	Aspect in degrees azimuth
3	Slope	Nachylenie wyrażone w stopniach	Slope in degrees
4	Horizontal_Distance_To_Hydrology	Dystans horyzontalny do najbliszszego zbiornika wodnego	Horizontal distance to nearest surface water features
5	Vertical_Distance_To_Hydrology	Dystans wertykalny do najbliszszego zbiornika wodnego	Vertical distance to nearest surface water features
6	Horizontal_Distance_To_Roadways	Dystans horyzontalny do najbliższej drogi	Horizontal distance to nearest roadway
7	Hillshade_9am	Cieniowanie, zakres od 0 do 255, o godzinie 9, w dniu przesilenia	Hillshade index at 9am, summer solstice (0 to 255 index)
8	Hillshade_Noon	Cieniowanie, zakres od 0 do 255, w południe, w dniu przesilenia	Hillshade index at noon, summer solstice (0 to 255 index)
9	Hillshade_3pm	Cieniowanie, zakres od 0 do 255, o godzinie 3, w dniu przesilenia	Hillshade index at 3pm, summer solstice (0 to 255 index)
10	Horizontal_Distance_To_Fire_Points	Dystans horyzontalny do najbliższej stacji straży pożarnej	Horz Dist to nearest wildfire ignition points
11	Wilderness_Area	Obszar, wyrażony binarnie, w 4 kolumnach	Wilderness area designation
12	Soil_Type	Rodzaj gleby, wyrażony binarnie, w 40 kolumnach	Soil Type designation (40 binary columns, 0 = absence or 1 = presence)
13	Cover_Type	Docelowy typ zalesienia, wartości od 1 do 7	Forest Cover Type designation (7 types, integers 1 to 7)

3.2.2 Typy obszarów

Lp.	Nazwa
1	Rawah Wilderness Area
2	Neota Wilderness Area
3	Comanche Peak Wilderness Area
4	Cache la Poudre Wilderness Area

3.2.3 Rodzaje gleb

Lp.	Nazwa	Opis
1	Cathedral family	Rock outcrop complex, extremely stony
2	Vanet	Ratake families complex, very stony
3	Haploborolis	Rock outcrop complex, rubbly
4	Ratake family	Rock outcrop complex, rubbly
5	Vanet family	Rock outcrop complex complex, rubbly
6	Vanet - Wetmore families	Rock outcrop complex, stony
7	Gothic family	-
8	Supervisor	Limber families complex
9	Troutville family	Very stony
10	Bullwark - Catamount families - Rock outcrop complex, rubbly	-
11	Bullwark - Catamount families - Rock land complex, rubbly	-
12	Legault family	Rock land complex, stony
13	Catamount family	Rock land - Bullwark family complex, rubbly
14	Pachic Argiborolis	Aquolis complex
15	unspecified in the USFS Soil and ELU Survey	-
16	Cryaquolis	Cryoborolis complex
17	Gateview family	Cryaquolis complex
18	Rogert family, very stony	-
19	Typic Cryaquolis	Borohemists complex
20	Typic Cryaquepts	Typic Cryaquolls complex
21	Typic Cryaquolls	Leighcan family, till substratum complex
22	Leighcan family, till substratum, extremely bouldery	-
23	Leighcan family, till substratum - Typic Cryaquolls complex	-
24	Leighcan family, extremely stony	-
25	Leighcan family, warm, extremely stony	-
26	Granile	Catamount families complex, very stony
27	Leighcan family, warm	Rock outcrop complex, extremely stony
28	Leighcan family	Rock outcrop complex, extremely stony
29	Como	Legault families complex, extremely stony
30	Como family - Rock land	Legault family complex, extremely stony
31	Leighcan	Catamount families complex, extremely stony
32	Catamount family - Rock outcrop	Leighcan family complex, extremely stony
33	Leighcan - Catamount families	Rock outcrop complex, extremely stony
34	Cryorthents	Rock land complex, extremely stony
35	Cryumbrepts - Rock outcrop	Cryaquepts complex
36	Bross family - Rock land	Cryumbrepts complex, extremely stony
37	Rock outcrop - Cryumbrepts	Cryorthents complex, extremely stony
38	Leighcan - Moran families	Cryaquolls complex, extremely stony
39	Moran family - Cryorthents	Leighcan family complex, extremely stony
40	Moran family - Cryorthents	Rock land complex, extremely stony

4 Wstępna analiza danych

Wstępna analiza danych została przedstawiona w tabeli poniżej, gdzie zostały policzone podstawowe wartości, takie jak ilość unikalnych wartości atrybutu, wartość minimalna, maksymalna, czy mediana.

4.1 Podsumowanie dostępnych danych

Liczba przykładów trenujących: 15120 Liczba kolumn: 56 Rozkład obszarów zalesienia:

Typ lasu	1	2	3	4	5	6	7
Ilość przykładów	2160	2160	2160	2160	2160	2160	2160

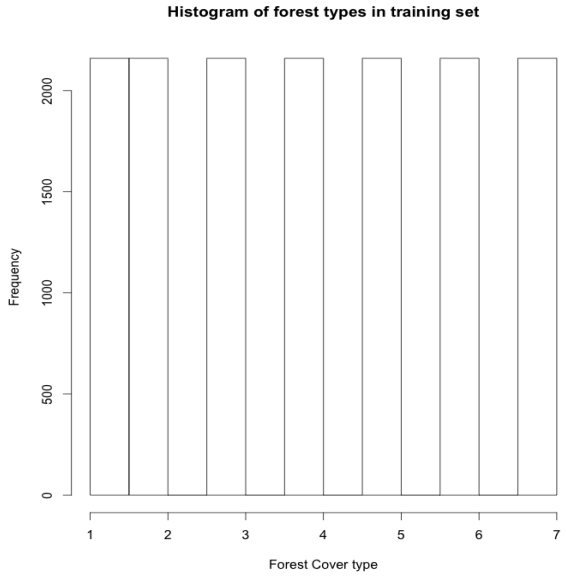

- Zbiór trenujący zawiera 15120 wierszy, wraz z 56 kolumnami
- Kolumna 1 reprezentuje ID danego wpisu
- Kolumny 2-11 reprezentują atrybuty ilościowe
- Kolumny 12-15 to reprezentacja binarna obszaru *Wilderness_Area* (4 kolumny wzajemnie się wykluczające: ComachePeak, CachePodure, Neota, Rawah)
- Kolumny 16-55 to reprezentacja binarna typu gleby *Soil_Type* (40 kolumn wzajemnie się wykluczających)
- Kolumna *Cover_Type* zawiera 7 wartości (docelowa klasyfikacja)
- Kolumny binarne wzajemnie się wykluczają

Największą zależność, pod względem przypisania do klasy docelowej, wykazuje atrybut *Elevation*, który to został przedstawiony na poniższym wykresie pudełkowym:

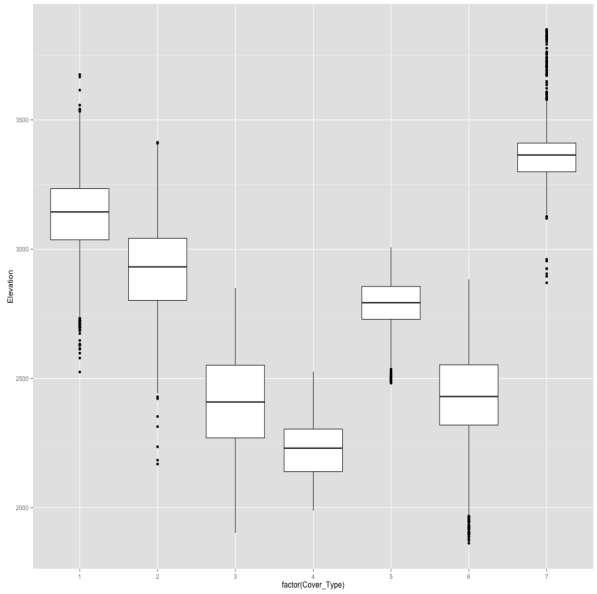

Można więc się spodziewać, że na przykład w przypadku zastosowania algorytmu C4.5 będzie on stanowił atrybut wyjściowy, od którego algorytm będzie zaczynać budowanie drzewa, a dopiero analiza kolejnych wartości atrybutów pozwoli na dokładniejsze zaklasyfikowanie próbki.

4.2 Atrybut dyskretny reprezentujący pojęcie docelowe

Atrybutem reprezentującym pojęcie docelowe jest typ lasu. Jest to zbiór liczbowy, składający się z siedmiu wartości:

Lp.	Nazwa	Nazwa (j.ang.)
1	Świerk/jodła	Spruce/Fir
2	Sosna wydmowa	Lodgepole Pine
3	Sosna żółta	Ponderosa Pine
4	Topola/wierzba	Cottonwood/Willow
5	Topola osikowa	Aspen
6	Daglezja zielona	Douglas-fir
7	Drzewo karłowate	Krummholz

4.3 Przetworzenie do odpowiedniej postaci

Zbiór danych trenujących jest dostępny do pobrania w postaci pliku csv. Jest on wczytywany za pomocą komendy read.csv do formatu data.frame.

Algorytm najbliższych sąsiadów jako argument danych treningowych/testujących może przyjmować dane w tym właśnie formacie, podobnie jak naiwny klasyfikator bayesowski i algorytm C4.5.

4.3.1 Modyfikacja atrybutów

Ze względu na wzajemne wykluczanie się wartości przechowywanych w kolumnach 12-15, opisujących *Wilderness_Area*, atrybut ten został złączony w jeden, przyjmujący wartości dyskretne od 1 do 4, gdzie jego liczba porządkowa przypisana jest do typu obszaru opisanego w tabeli Typy obszarów.

Podobna optymalizacja została przeprowadzona dla typów gleb *Soil_Type* (kolumny 16-55), z tego samego powodu. Przyjmują one więc wartości dyskretne od 1 do 40 zgodnie z tabelą Rodzaje gleb.

4.3.2 Eliminacja/naprawa defektów danych

Dane nie zawierają brakujących danych, dlatego też nie będzie potrzebna estymacja wartości atrybutów dla danych brakujących. Ewentualne defekty w danych mogą występować ze względu na źródło danych, skąd zostały one pobrane (USFS), jednak przy realizacji tego projektu zakładamy ich poprawność, ze względu na trudność lokalizacji ewentualnych błędów.

4.3.3 Modyfikacja rozkładu klas

Klasy w zestawie danych testowych rozkładają się równomiernie, dlatego też nie zostanie przeprowadzona modyfikacja ich rozkładu.

4.3.4 Losowanie podzbiorów danych

Ze względu na równy podział klas, losowanie podzbiorów danych wykonywane będzie z uwzględnieniem sprawiedliwego podziału rozkładu klas pomiędzy zbiorami danych trenujących. Oznacza to, iż każdy podzbiór danych zbioru trenującego będzie zawierać równą ilość klas konkretnego typu tak, aby w modelu uczącym się żadna z klas nie mogła zdominować pod względem jej wyboru.

4.3.5 Możliwość zdefiniowania nowych atrybutów

Możliwość definicji nowych atrybutów może wyniknąć z korelacji zachodzących pomiędzy istniejącymi atrybutami. Korelacja zaobserwowana będzie w trakcie dalszej części realizacji projektu, na podstawie graficznej reprezentacji atrybutów.

4.3.6 Ustalenie kryteriów lub algorytmu selekcji atrybutów

Parametry algorytmów wymagające dostrojenia

Naiwny klasyfikator Bayesowski

- ustalenie wartości *threshold*, którą będą zastępowane prawdopodobieństwa równe zeru bądź mniejsze od ϵ
- ustalenie granicy prawdopodobieństwa - ϵ, która będzie zastępowana wartością threshold

Algorytm k-najbliższych sąsiadów

- ustalenie wartości k - ilu najbliższych sąsiadów ma być branych pod uwagę
- ustalenie wartości l - minimalna ilość głosów potrzebna do podjęcia ostatecznej decyzji

4.3.7 Miary jakości i ocena modelu

Ocena modelu polega na ocenie według dwóch kategorii:

1. Trafność klasyfikacji (Classification / Predictive accuracy)
   (a) Miary True Positive Rate, True Negative Rate
   (b) Macierz pomyłek
   (c) Analiza krzywej ROC
   (d) Feature importance
2. Szybkość i skalowalność
   (a) czas uczenia się
   (b) szybkość klasyfikowania

5 Implementacja i wyniki

5.1 Stworzone modele

5.1.1 Algorytm C.45

Algorytm C4.5 został zaimplementowany jako funkcja *J48* w pakiecie RWeka. Model, oprócz danych treningowych, przyjmuje również jako argumenty opcje, którymi można dostroić algorytm. Główne parametry budowania klasyfikatora C4.5 to:

- U - Stosowanie nieprzyciętych drzew
- O - Nie zapadaj drzewa
- C - Granica prawdopodobieństwa rozkładu klas dla którego przycinamy drzewo (domyślnie 0,25)
- M - Minimalna liczba przykładów, aby utworzyć liść w drzewie (domyślnie 2)
- R - Używaj przycinania na podstawie redukcji błędu
- N - Na ile zbiorów powinny zostać podzielone dane treningowe, jeśli używamy przycinania na podstawie redukcji błędu (domyślnie 3)
- B - Używaj jedynie podziałów binarnych w drzewie

Tworzenie samego modelu drzewa decyzyjnego zostało przetestowane dla różnych opcji:

- wszystkie opcje klasyfikatora z domyślnymi wartościami

Correctly Classified Instances	9311	61.5807 %
Incorrectly Classified Instances	5809	38.4193 %

- (Weka control: Do not collapse tree, O = TRUE)

Correctly Classified Instances	9311	61.5807 %
Incorrectly Classified Instances	5809	38.4193 %

- tworzenie jedynie binarnych podziałów (Weka control: Use binary splits only, B = TRUE)

Correctly Classified Instances	12529	82.8638 %
Incorrectly Classified Instances	2591	17.1362 %

- nieprzycinanie drzew (Weka control: Use unpruned tree, U = TRUE)

Correctly Classified Instances	13809	91.3294 %
Incorrectly Classified Instances	1311	8.6706 %

Spośród przetestowanych modeli wybrano najlepszy. Model ten został następnie przetestowane za pomocą metody cross-validation: dzielono zestaw danych treningowych na k podzbiorów o równej liczności, a następnie uczono model na jednym z tych zbiorów i testowano na *(k-1)* pozostałych. Przetestowano tą metodę dla każdego $k \in \{1, ..., |training\_data|\}$. Sprawdzono w ten sposób stabilność algorytmu.

Wydawałoby się, że najlepsze wyniki zostały uzyskane przy zablokowaniu przycinania drzew - daje ono największy odsetek dobrze sklasyfikowanych przykładów. Istnieje jednak niebezpieczeństwo, że jest to kwestia nadmiernego dopasowania drzewa do danych treningowych. Za pomocą metody cross-validation widać, że obawy potwierdzają się - przy dzieleniu danych na mniejsze zbiory, jakość klasyfikatora natychmiast spada. Poniżej przedstawiono wykres zależności stopnia poprawnie sklasyfikowanych przykładów od ilości zbiorów na które podzielono zbiór treningowy.

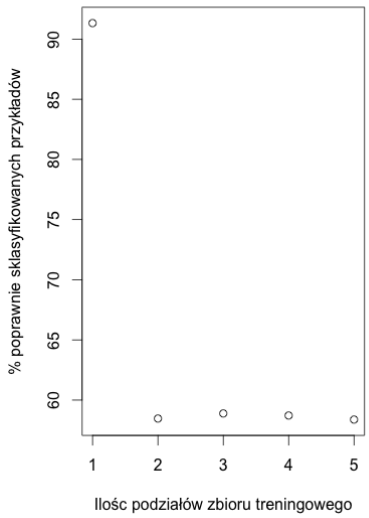

W związku z tym, za najlepszą metodę uznano uzyskiwanie drzewa jedynie przy podziałach binarnych. Kolejnym etapem jest maksymalne przycięcie drzewa, które jednocześnie nie powodowałoby dużej straty jakości modelu. Jest to ustalane za pomocą opcji M, które ustala minimalną liczbę przykładów, dla których może być utworzony liść - domyślnie jest to liczba 2. Niestety powiększanie tej wartości ma mocny wpływ na jakość modelu, co można zobaczyć na wykresie poniżej.

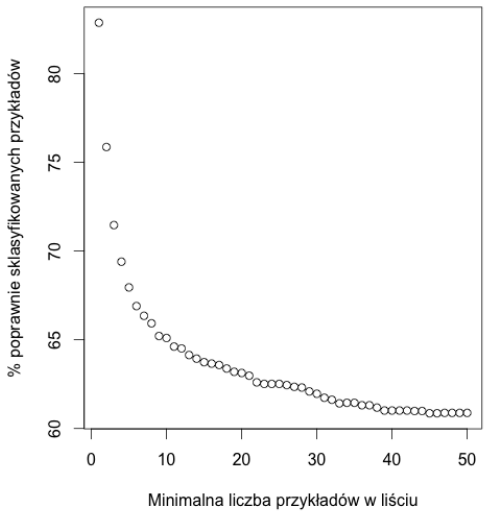

W związku z tym domyślna wartość pozostanie aby nie stracić poziomu minimalizacji. Ostatnim etapem jest upewnienie się, że stworzony model jest odporny i zachowuje swoją

skuteczność przy trenowaniu na podzielonych zbiorach danych.

5.1.2 Naiwny klasyfikator Bayesowski

5.1.3 Algorytm k-najbliższych sąsiadów

Algorytm k-najbliższych sąsiadów został zaimplementowany jako funkcja *IBk* w pakiecie RWeka.

Tworzenie samego modelu klasyfikacji zostało przetestowane dla różnych opcji:

- wszystkie opcje klasyfikatora z domyślnymi wartościami

Correctly Classified Instances	15120	100 %
Incorrectly Classified Instances	0	0 %

Model jest jednak zbytnio dopasowany, dlatego przy sprawdzaniu modelu metodą cross-validation, jego jakość drastycznie spada:

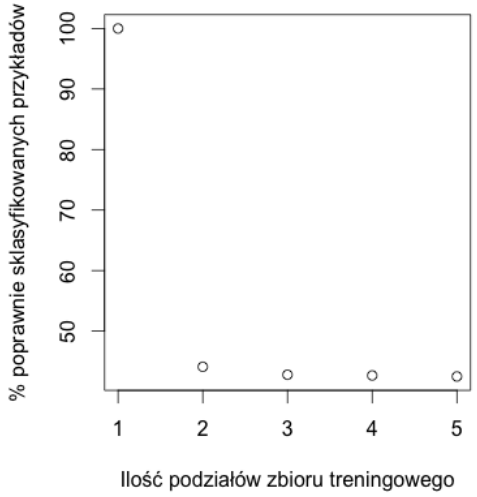

Przy zwiększaniu liczby branych pod uwagę sąsiadów, jakość klasyfikatora również spada:

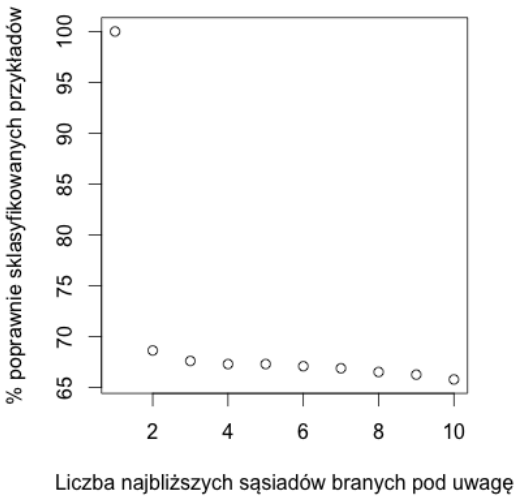

5.2 Ocena stworzonych modeli

5.2.1 Algorytm C4.5

5.2.2 Naiwny klasyfikator Bayesowski

5.2.3 Algorytm k-najbliższych sąsiadów